Modelos de Aprendizaje

- Supervisado (X, Y)
- No supervisados
  - → Descubrir etiquetas en grupos de datos (clustering)
  - → Reducción / Expasión

$$X \in \mathbb{R}^{n \times k} \rightarrow X' \in \mathbb{R}^{n \times d}$$

(PCA - Principal Component Analysis)
(SVD - Factorización por Autovalores)

Aprendizaje Supervisado

Espacio de características

↳ Espacio numérico

↳ Espacio de análisis (aprendizaje)

↙ X — características predictivas

↘ y — características de respuesta

Fenómeno: Accidentes de tránsito

- Fecha / Hora
- Tipo Auto
- Sexo conductor
- Cinturón de seguridad
- Alcoholizado
- Edad
- Fatal

Espacio - características

- Año | - Año
- Mes * | - Trimestre*
- Día (M) | - Día (W)*
- Hora | - Horario *
- - P. Vacacional*
- Tipo A *
- sexo *
- Cinturón S.*
- Alcoholizado *
- Edad | G. Edad *
- Fatfal * - Gravedad Ac.

Espacio numérico

- Fatal
- Gravedad Ac.

} Características de Respuesta

- Año
- Mes
- Día
- ...
- Sexo
- Cinturón
- ...
- G. Edad

Características Predictivas

Espacio de análisis (aprendizaje)

Fenómeno: Supervivencia en el Titanic

- sexo
- Edad
- Clase
- Familia
- T. viaje
- Tarifa
- Cabina
- P. Embarcación
- Sobrevive

- Mujer (1/0)
- Edad (-)
- 1ra (1/0)
- 2da (1/0)
- Familia (-)
- V. Pareja (1/0)
- V. Familia (1/0)
- Tarifa (! log1p) - rmín tarif.
- Cabina (1/0)
- C (1/0)
- Q (1/0)
- X (1/0)
- Sobrevive (1/0)

$\mathbb{R}^{891 \times 13}$

- Sobrevive (1/0)
- Mujer (1/0)
- Edad (-)
- ...
- C (1/0)
- Q (1/0)
- X (1/0) !< 1%

Modelo de aprendizaje

ML (directos) → DL (complejos)

→ Función Generalizada Parametrizada

Función → Curva (1-D) x_1
→ Superficie (2-D) x_1, x_2
→ Variedad (3+-D) $x_1, \ldots, x_K$

Modelo de Predicción

Modelo paramétrico (β)

$$\hat{y} = \varphi(X, \beta)$$

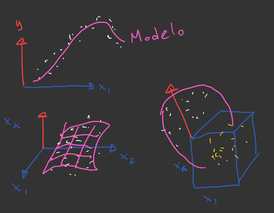

predictiva

$y = mx + b$

pendiente (tangente) — intercepto (bias)

respuesta (predicción)

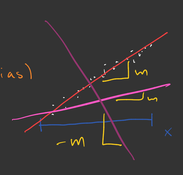

Ajustar

$m \in \mathbb{R}$

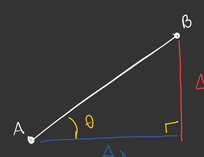

$$m = \tan\theta = \frac{\Delta y}{\Delta x}$$

pendiente

$$\theta = \arctan(m)$$

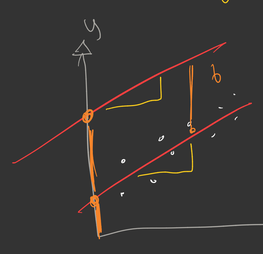

Ajustar

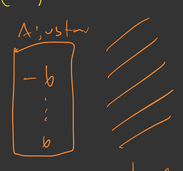

$b \in \mathbb{R}$

Error entre la predicción del modelo $\hat{y}$ y la respuesta real y

$$\varepsilon^{(i)} = y^{(i)} - \hat{y}$$

Un error (i) por cada observación

$$\underbrace{\varepsilon_T}_{L} = \frac{\sum_{i=1}^{n} \left(\varepsilon^{(i)}\right)^2}{2}$$

función de pérdida

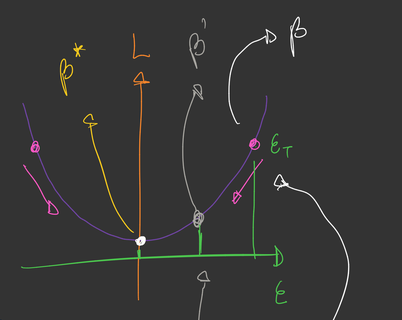

$\beta = (m, b)$

$\beta' = (m', b')$

Optimización

$$\min_{\beta^*} L$$

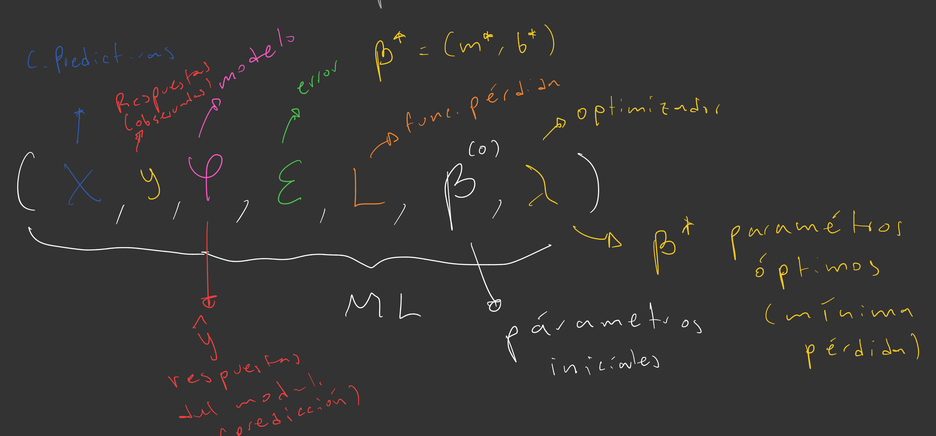

$$\hat{y} = mx + b$$

$$\hat{y} = \beta_0 + \beta_1 x$$ Modelo lineal Simple

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_K x_K$$

$$(1, x_1, x_2, \ldots, x_K) \cdot \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{pmatrix}$$ → parámetros (pesos de aprendizaje)

$$\hat{y} = \varphi(X, \beta)$$

$$z = \underbrace{X \cdot \beta}$$

Predictor lineal

$\varphi(X \cdot \beta)$ $\quad \varphi(z) = z$

$$\hat{y} = z$$

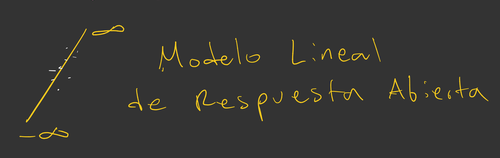

Modelo Lineal de Respuesta Abierta

$$\hat{y} = \frac{e^z}{1 + e^z}$$

$$\hookrightarrow \frac{1}{1 + e^{-z}}$$

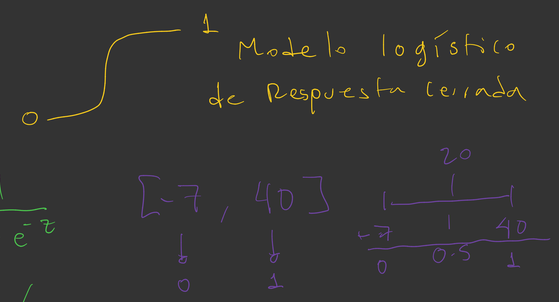

Sigmoide / Curva Logística

$$\varphi(z) = \frac{e^z}{1 + e^z}$$

MSE / Error cuadrático medio

$$L = \frac{1}{2} \sum \|\varepsilon\|^2$$

$$L = \underbrace{-y \ln(y - \varepsilon) - (1 - y)\ln(1 - y + \varepsilon)}$$

Entropía Cruzada Binaria

$$\lambda(\beta^{(0)}, L)$$

Optimizando por Descenso de Gradiente

$$\beta^{(1)} = \beta^{(0)} - \eta \nabla_\beta L$$

$$\boxed{\beta^{(1)} = \beta^{(0)} - \eta X^T \varepsilon}$$

Optimización de los parámetros

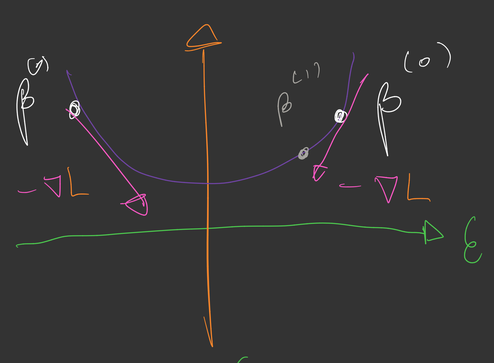

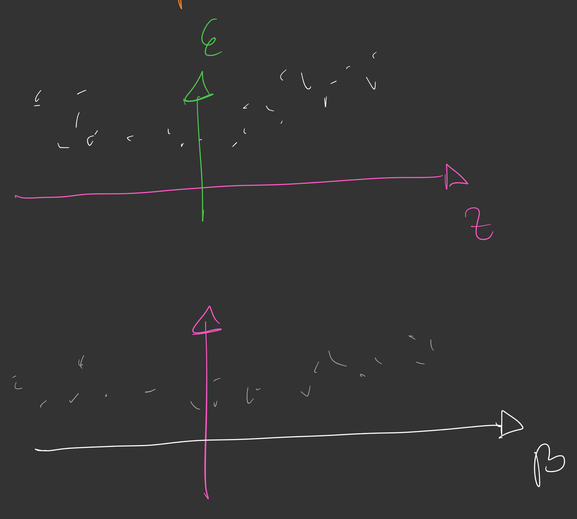

$$\beta^{(1)} - \beta^{(0)} \quad \alpha \quad -\nabla L$$

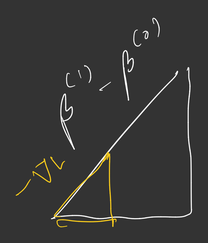

$$\beta^{(1)} - \beta^{(0)} = -\eta \nabla_\beta L$$

$$\beta^{(1)} = \beta^{(0)} - \eta \nabla_\beta L$$

Problema de aproximación lineal

↳ Red Neuronal

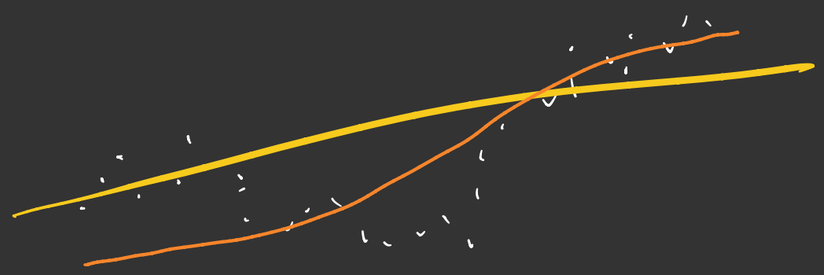

← ∇E / J_L

Retropropagación del error

(backpropagation)

Entrada

Oculta 1

Oculta 2

Salida

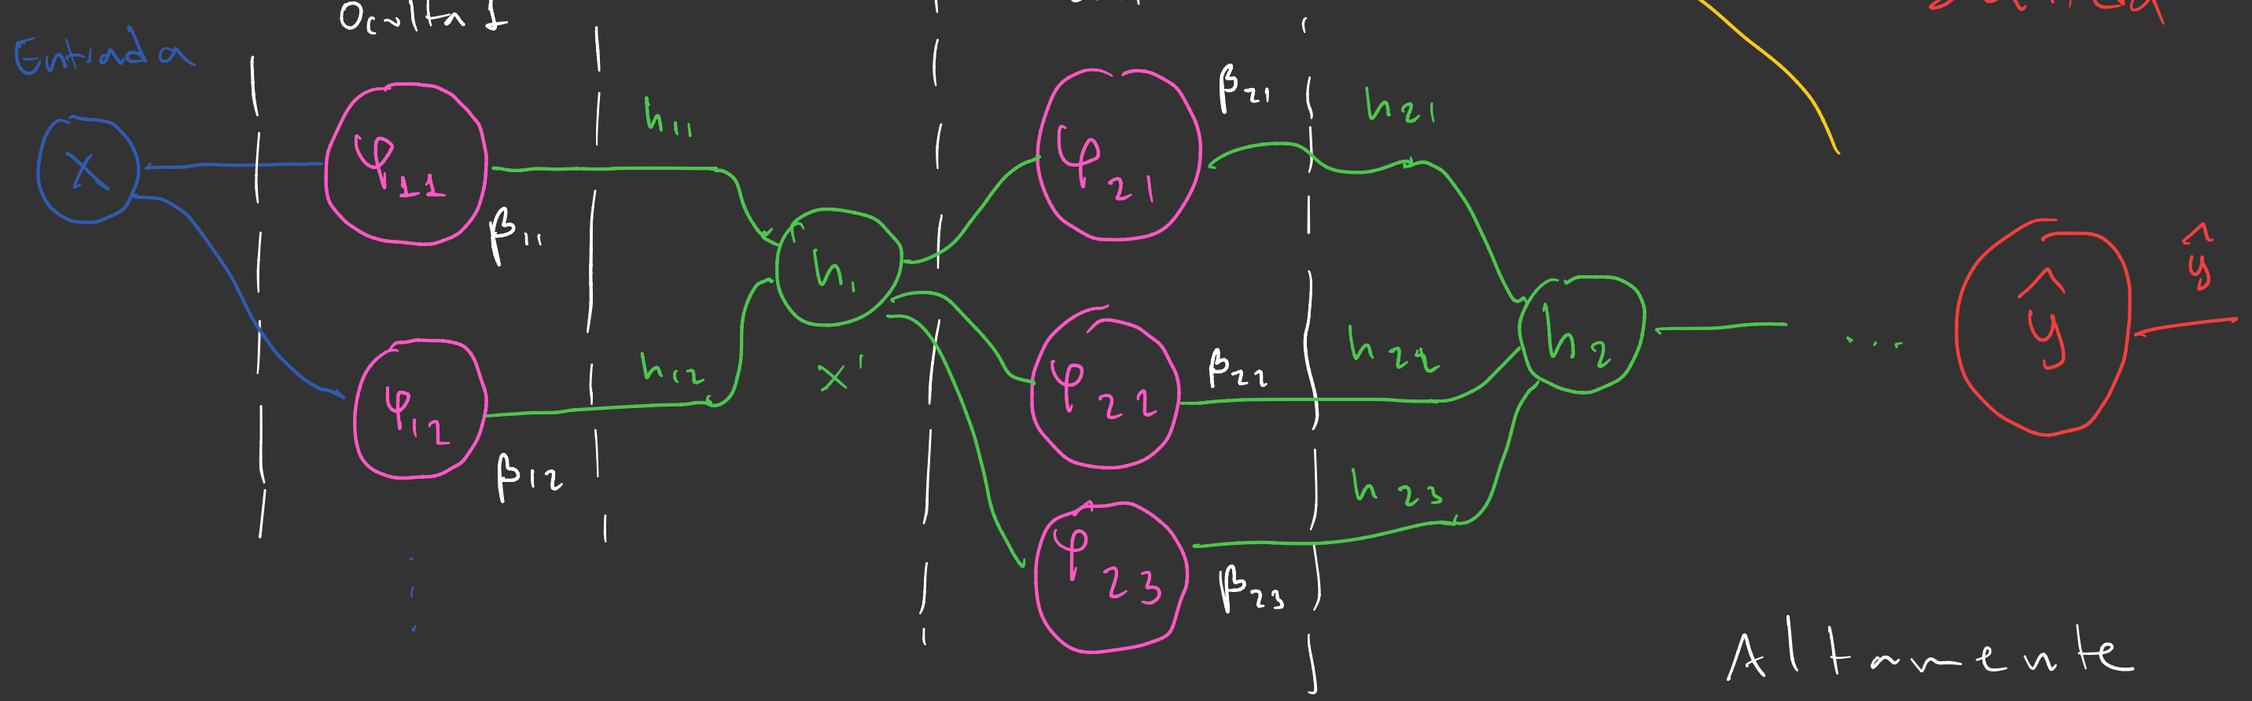

2 × 3

Altamente no lineal