LLM (Large Language Model)

Modelo de Amplio Lenguaje

- Espacio Semántico

texo → Números

(Distancia semántica)

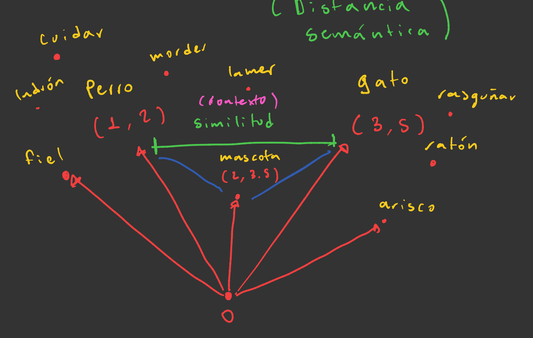

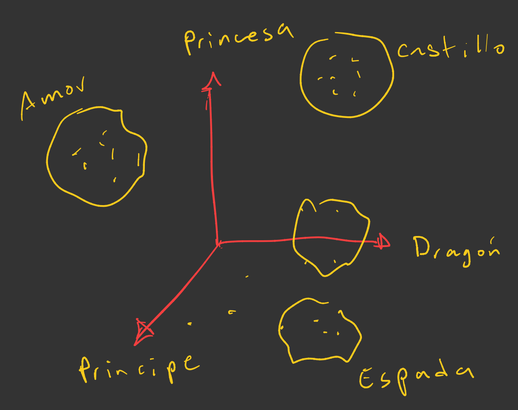

Espacio Semántico

↓

Posición espacial en las altas dimensiones semánticas se conocen como el EMBEDDING

Fuente amplia de texto (corpus)

	Gramática	Semántica	Dimensión (Diversidad)	
- Noticias	Buena	Regular	Regular	✗
- Literatura	Buena	Buena	Muchas	✓
- Cuentos	Buena	Regular	Regular	✗
- Biblia	Buena	Buena	Regular	✗
- Tweets	Mala	Mala	Muchas	✗

Pasos para construir un LLM

1. Tener un Corpus
2. Tokenizar (Sentencia o frase, contexto) → Fragmento (token)

Tipos de token
- palabra / espacio (signo de espacio)
- palabra / espacio / puntuación (signo de espacio / signo de puntuación)
- n-gramas (3-grama: 3 letras o signos)
- Tronco / lema / puntuación (base / raíz)

¿Hola cómo estás este otoño?

<hola><espacio><como><espacio><estas><espacio><este><espacio><otono>

<PS> <PS> <PS> <PS>

<IA><MA><h><o><l><a><PS><c><o><AC><m><o>...<t><o><n><TI><o>...<IC>

3-grama <IA><MA><h>
<o><l><a>
⋮

Diccionario (Bag of words)

Identica e Indexa los tokens únicos

Corpus: Anita lava la tina

<anita><ps><lava><ps><la><ps><tina>

{
<anita>: 1
<ps>: 2
<lava>: 3
<la>: 4
<tina>: 5
}

Vector índice (vectorizador) → (1, 2, 3, 2, 4, 2, 5) → sequence (secuencia)

RNN { LSTM, GRU

$$\begin{array}{c|cccc} & 1 & 2 & 3 & 4 \\ \hline 1 & & & & \\ 2 & & & & \\ 3 & & & & \\ 4 & & & & \end{array}$$ ✗ semántica

El príncipe encontró al dragón ...
El dragón atacó al príncipe ...
El dragón fue herido por el príncipe ...
El príncipe logró matar al dragón ...

T<el> (contexto)

T<principe> { <encontro> <al> <dragon> <logro> <matar> }

T<dragon> { <ataco> <al> <principe> <fue> <herido> <por> <el> ... }

18,523 ... <el> ... <principe> ... <dragon> ...

$$\begin{array}{c|ccccc} & \cdots & & & & \\ \hline <el> & 0 & & 0.6\ldots & & 0 \\ \vdots & & \ddots & & & \\ <principe> & 0 & & 0 & & 0 \\ \vdots & & & & \ddots & \\ <dragon> & 0 & 0 & & & 0 \\ \vdots & & & & & \end{array}$$

18,523 × 18,523 → W

$18{,}523^2 \approx 10^{10}$

1, 4, 6, 1

1, 0.25, 0.16̄, 1

PMI: $\boxed{0.6..}$

$\frac{2.41}{4}$

Matriz Sparse

↳ Factorización ✓ / ~~PCA~~

$W = L \Sigma R$ (SVD)

↳ Autovalores (eigenvalores) λ_i

$Ax = b \mid Ax = x$ ↳ $(A - \lambda)x = 0$ ↳ 0

↑ espectros / valores propios

$W \approx L\Sigma$ (18,523 → 8)

↳ comprimir y factorizar W

	características
Embedding real	18,523
Embedding comprimido	8

sentencia
↓
tokens
↓
embedding
↓
red neuronal → QKV ← 7B (atención)
↓
modelo preentrenado

LLM

$ LLM Local 7B

Qwen 3 - 3GB / 8GB

$$$$ LLM Remoto 200B

ChatGPT-5 96GB / 2TB